

Organisation nationale de lutte contre le faux- monnayage (ONCFM)

MODULE 12 – FORMATION DATA ANALYST - OPENCLASSROOMS



SOMMAIRE

- Contexte et présentation
- Nettoyage des données
- Analyse exploratoire
- Exécution et comparaison des modèles
- Mise en œuvre de l'application




LE JEU DE DONNÉES


- 1500 billets : 1000 vrais et 500 faux
- 1 variable catégorielle : vrai ou faux billet



LES VALEURS EXTREMES



LIEN ENTRE LES VARIABLES




UN JEU DE DONNÉES INCOMPLET



37 variables manquantes
pour la variable margin_low

Nécessité de compléter les données
avant de lancer les modèles




Choix de la régression linéaire
pour compléter les données.

	Nb_Features	Features	R2	RMSE	MAE	MAPE_%
0	1	length	0.5136	0.4528	0.3443	7.71
1	2	margin_up	0.5139	0.4526	0.3440	7.69
2	3	height_right	0.5272	0.4464	0.3386	7.54
3	4	height_left	0.5393	0.4407	0.3367	7.50
4	5	diagonal	0.5458	0.4375	0.3354	7.47




UN NOMBRE DE VARIABLES QUI GARANTIT UNE PLUS GRANDE PRECISION




UNE IMPUTATION SOLIDE

Distribution des résidus (Erreurs)




Analyse des résidus : Vrais vs Faux Billets



VRAI BILLET CONTRE FAUX BILLET

Visualisation Réaliste : Prise en compte de l'asymétrie (Gauche vs Droite)



LA MISE EN ŒUVRE DES ALGORITHMES



Le K-means

La régression logistique

Le KNN

La random forest

LES PERFORMANCES DES MODÈLES

🇫🇷 RÉCAPITULATIF COMPLET DES ALGORITHMES POUR L'EMV

	Modèle	Type	Accuracy (%)	Recall	Précision	F1-Score	AUC Score	Faux Négatifs (FN)	Faux Positifs (FP)	
1	KNN	Supervisé (Test)	99.33	0.995	0.995	0.9950	0.9994	1	1	
0	Régression Logistique	Supervisé (Test)	99.00	0.995	0.990	0.9925	0.9995	1	2	
2	Random Forest	Supervisé (Test)	99.00	0.995	0.990	0.9925	0.9994	1	2	
3	K-means (Centroïdes)	Non-Supervisé (Test)	98.67	0.990	0.990	0.9900	N/A	2	2	



Merci
à vous